

Búsqueda Semántica en Español

Comparación de Representaciones Vectoriales de Texto

Alejandro Vásquez Sánchez

Proyecto Final — Inteligencia Artificial

May 28, 2026

¿De qué va esta presentación?

- 1 El problema y por qué importa
- 2 La idea clave: palabras como números
- 3 Los cinco métodos que comparé
- 4 Cómo funciona mi modelo (Word2Vec)
- 5 Cómo lo entrené y lo evalué
- 6 Resultados
- 7 Lecciones y trabajo futuro

En una frase:

¿Cómo logramos que un buscador entienda lo que queremos decir, y no solo las palabras exactas que escribimos?

1. El problema y su motivación

El problema:

Los buscadores tradicionales comparan **palabras exactas**. Fallan cuando preguntamos con otras palabras.

Ejemplo:

Busco “*computadora*”
pero el texto dice “*ordenador*”.
→ un buscador literal **no los conecta**.

La meta:

Un buscador que entienda el **significado**, no solo las letras.

¿Por qué importa?

Es la base de Google, los asistentes de voz, los chatbots y los sistemas de preguntas y respuestas.

2. La idea clave: convertir palabras en números

Cada palabra se convierte en un **vector** (una lista de números).

Palabras con significados parecidos quedan **cerca** en el espacio.

Entonces “buscar” se vuelve algo geométrico:
encontrar los vectores más cercanos a la pregunta.

“Una palabra se conoce por la compañía que tiene”

(Principio de Firth, 1957 — la base de todo el proyecto)

rey $\approx [0.2, -0.5, 0.8, \dots]$

reina $\approx [0.3, -0.4, 0.7, \dots]$

(ceranos porque significan cosas parecidas)

3. Los cinco métodos comparados

Método	Tipo	En una frase
TF-IDF	Clásico (palabras)	Cuenta palabras exactas. No entiende sinónimos.
Word2Vec (propio)	Entrenado por mí	Aprende significado del contexto. Mi modelo.
Word2Vec (gensim)	Librería	El mismo modelo, versión profesional.
GloVe	Preentrenado	Vectores ya entrenados por otros.
Sentence-Transformers	Moderno (Transformer)	Entiende oraciones completas en contexto.

De lo más simple (arriba) a lo más sofisticado (abajo).

4. ¿Cómo funciona mi modelo? (Word2Vec Skip-gram)

La tarea de entrenamiento:

Dada una palabra, predecir qué palabras aparecen **a su alrededor**.

“El **gato** duerme en el sofá”

Si le doy “gato”, debe aprender que cerca aparecen “duerme”, “sofá”...

Dos trucos clave que implementé:

Negative sampling: en vez de revisar TODO el diccionario en cada paso (lentísimo), solo compara con unas pocas palabras al azar.


Subsampling: ignora un poco las palabras muy comunes (“de”, “la”) que no aportan significado.

5a. ¿Cómo lo entrené?

Datos: Wikipedia en español
(50.000 artículos, 25 millones de palabras)

Configuración:

- Optimizador: Adam
- Tasa de aprendizaje: 0.005
- Épocas: 15
- Batch: 4.096
- Hardware: GPU Tesla T4 (Colab)
- Tiempo: ~4 horas



La pérdida baja y se estabiliza: el modelo aprendió bien.

5b. ¿Cómo lo evalué?


Datos de prueba: mMARCO

Preguntas reales en español con su respuesta correcta conocida (5.000 documentos, 200 preguntas).

Dos métricas:



Precisión@K: ¿está la respuesta correcta entre los primeros K resultados?

MRR: ¿qué tan arriba aparece la respuesta correcta?



La **X roja** es la pregunta; la estrella dorada es la respuesta correcta. Están **juntas** → ¡el buscador funciona!

6. Resultados






Ganador: Sentence-Transformers (63% acierto al primer intento).
simple) quedó **segundo**.

Sorpresa: TF-IDF (el más

¿Qué aprendió realmente el modelo?

Agrupación semántica por categorías



Sin que nadie se lo dijera, las palabras se agrupan solas por categoría: **países, ciudades, días, meses, familia, animales.**

7. Lecciones aprendidas y trabajo futuro

Lecciones:

- No hay un único “mejor” método: depende del problema.
- Lo moderno (Transformers) gana en calidad...
- ...pero lo simple (TF-IDF) sigue siendo muy competitivo y rapidísimo.
- Implementar desde cero enseña muchísimo más que usar una librería.

Trabajo futuro:

- Entrenar con más datos y más tiempo.
- Combinar métodos (TF-IDF + semántico).
- Probar en otros idiomas o dominios específicos (medicina, leyes).
- Mejorar cómo se representa un documento completo, no solo promediar palabras.

¡Gracias!

Búsqueda Semántica en Español

Alejandro Vásquez Sánchez

¿Preguntas?